

GeoChat¹基础大型视觉语言模型for遥感

Kartik Kuckreja^{1,2*} Muhammad Sohail Danish^{1*} Muzammal Naseer¹ Abhijit Das² Salman Khan^{1,3} Fahad Shahbaz Khan^{1,4} 阿联酋人工智能大学,²伯拉学院与科学学院, 海得拉巴³澳大利亚国立大学,⁴Linköping大学 kartik.kuckreja@mbzuai.ac.ae,
muhammad.sohail@mbzuai.ac.ae

摘要

近年来, 大型视觉语言模型 (VLMs) 在自然图像领域取得了显著进展, 允许用户就给定视觉内容进行对话。然而, 这类通用领域VLMs在遥感 (RS) 场景中表现不佳, 当面对RS领域特定查询时, 会提供不准确或虚构的信息。这种行为源于RS图像带来的独特挑战。例如, 为了处理具有跨类别多样尺度变化和许多小对象的高分辨率RS图像, 需要结合整体场景解释进行区域级推理。此外, 缺乏RS领域的多模态指令遵循数据以及强大的RS主干模型, 使得模型难以使其行为与用户查询对齐。为解决这些限制, 我们提出了 **GeoChat**——首个提供高分辨率RS图像多任务对话能力的通用遥感VLM。具体而言, **GeoChat**不仅可以回答图像级查询, 还可以接受区域输入进行区域特定对话。此外, 它可以通过引用其空间坐标在响应中视觉定位对象。为解决领域特定数据集的缺乏, 我们通过扩展现有多样化RS数据集中的图像-文本对来生成一个新的RS多模态指令遵循数据集。我们建立了全面的RS多任务对话基准, 并与多种基线方法进行了比较。**GeoChat**在各种RS任务上表现出强大的零样本性能, 例如图像和区域描述、视觉问答、场景分类、视觉定位对话和指代检测。我们的代码可用 [在这里](#)。

1. 简介

在自然图像领域, 来自网络图像或手动标注的丰富对齐图像-文本数据, 促进了有效的自监督视觉语言建模, 这一点通过多模态 GPT- 和 LLaVA 等开源倡议得到了证明。

*同等贡献的第一作者。



图1. GeoChat可以在统一框架中为遥感 (RS) 图像理解完成多项任务。给定合适的任务标记和用户查询, 该模型可以生成视觉关联的响应 (带有相应对象位置的文本 - 显示在上方)、图像和区域的视觉问答 (分别显示在左上角和右下角) 以及场景分类 (右上角) 和正常自然语言对话 (底部)。这使得它成为第一个具有关联能力的遥感视觉语言模型 (RS VLM)。

标注4 [23]和开源倡议如 LLaVA [19]。这些视觉语言模型 (VLMs), 通过生成式预训练和指令微调开发而成, 在各种面向用户的多模态任务中表现出强大的零样本任务完成能力。这些能力为开发具有广泛现实场景应用的多模态对话助手打开了大门 [12]。

然而, 为自然图像设计的通用领域视觉语言模型, 在处理遥感视觉图像时表现不佳,

遥感视觉图像。性能差异主要源于**遥感图像-文本对内容的独特性**，与公开可用的网络数据存在显著区别。因此，通用领域视觉语言模型在处理来自遥感传感器的空间图像时，可能提供不准确的信息或产生幻觉。尽管遥感视觉问答（VQA）领域已取得显著进展 [38, 40]，早期方法将任务视为分类问题。在此，模型从训练数据中预定的响应中选择答案。这限制了它们在开放式答案生成和指令跟随方面的适用性。

在本文中，我们介绍了GeoChat，这是一个尝试将多模态指令微调扩展到遥感领域的尝试，用于训练一个多任务对话助手。然而，**遥感领域缺乏一个多模态指令微调对话数据集**。受近期指令微调 [14, 19, 41] 工作的启发，GeoChat使用Vicuna-v1.5 [7] 和一个自动化流程来生成多样化的遥感多模态指令遵循数据，包含近 318k 条指令。我们从为不同任务开发的现有遥感数据集中创建了图像-文本对。这些包括用于视觉问答的LR-BEN [20]、用于场景分类的NWPU-RESISC-45 [5] 以及用于目标检测的SAMRS [30]。

GeoChat的一个关键能力是在**单个流程中统一多个图像和区域级推理任务**，用于遥感图像（见图. 1）。我们通过不同的任务标记来实现这一点，这些标记有助于根据用户需求适当地指导模型的响应。此外，模型在其输入中使用空间位置表示，以无缝地推理局部区域，并且还可以在其响应中生成对象位置，以视觉定位对象。这使GeoChat能够支持多种任务，包括指代表达式检测、图像/区域描述、场景分类、自然语言对话和视觉问答，以及视觉 grounding 对话。

In summary，这项工作有以下贡献：

- **遥感多模态指令遵循数据集**。我们提出了一种新的数据生成流程，以利用现有的目标检测数据集 [30] 来创建图像的简短描述，然后使用Vicuna-v1.5 [7] 仅使用生成的文本来创建对话。此外，我们使用相应的数据集添加了视觉问答和场景分类能力 [5, 20]。这导致了遥感领域的 318k 指令对总数。
- **GeoChat**。利用我们的数据集，我们微调 LLaVA-1.5 [14] 来创建遥感领域的视觉语言模型 - GeoChat。我们的 LoRA [11] 微调是高效的，避免了忘记完全微调的 LLaVA 模型中嵌入的必要上下文，其 MLP 投影被训练以将图像对齐到 LLM (Vicuna-v1.5 [7]) 的词嵌入空间。这允许

GeoChat 保留 LLaVA 的对话和指令遵循能力，并将其领域知识扩展到遥感任务。

- 我们还解决了缺乏评估基准来评估现有VLM在遥感对话上的能力的问题。为此，我们为遥感中的对话基础设置了评估协议，以及一套任务来允许与该方向未来的努力进行比较。我们展示了各种监督和零样本评估，用于不同的遥感任务，包括图像描述、视觉问答和场景分类，以证明GeoChat对话VLM的泛化能力。

2. 相关工作

大型视觉语言模型。指令跟随型视觉语言模型（VLMs）的典型架构包括利用**预训练视觉主干** [9] 对视觉数据进行编码，使用**大型语言模型** [7] **对用户指令进行解释并生成响应**，以及一个**视觉语言跨模态连接器**，例如线性投影层 [18, 41] 或多层感知机 [17]，用于融合视觉信息与语言模型。VLMs取得的成果显示出巨大的潜力；例如，LLaVA [18]，Instruct-BLIP [8]，Otter [13] 和 MiniGPT-4 [41] 在自然场景的语言指令跟随和视觉推理能力方面表现出显著提升。最近的研究表明，这些模型可以适应其他领域，如视频 [22]，生物医学 [14, 29] 和遥感 [12]。

遥感视觉语言模型。广义视觉语言模型在遥感领域的应用相对较少。迄今为止，大多数研究忽视了物品及其关系的语义理解，从而难以实现深层次视觉理解。除了识别图像中的对象外，视觉语言模型还能够生成图像的自然语言描述，并推断对象之间的联系。这使得它们更适合基于文本的图像检索、图像描述和需要视觉和语言知识相结合的视觉问答等任务。尽管在遥感任务的视觉语言模型方面已经取得了一些进展，例如图像描述 [42]，零样本分类 [16] 和视觉问答 [3, 38]，但这些模型只能执行它们被训练过的特定任务，**缺乏对话能力，并且不具备关于遥感图像的通用语义知识**。在遥感领域，开发能够一起解决所有任务并保持对话能力的通用模型存在一个主要差距。虽然 RSGPT [12] 是一项初步尝试，它展示了良好的对话能力以及解决多个任务的能力，但它需要为每个任务单独微调模型，这使得它变得繁琐且无法泛化。而，RSGPT 不能用于区域级推理或视觉 grounding，这是我们工作的目标。

此外，RSGPT 不能用于区域级推理或视觉 grounding，这是我们工作的目标。

3. GeoChat: 接地遥感视觉语言模型

视觉 grounding 对话用于遥感旨在生成与相应对象位置交错出现的文本响应。此外，用户还可以在自然语言问题之外提供视觉提示（例如，边界框），而模型应该能够回答关于指定感兴趣区域 (RoI) 的问题。视觉和语言模态之间的这种无缝交互需要深入理解表示视觉场景中特定对象或元素的语言结构。

如上所述，GeoChat 是第一个能够就遥感图像进行视觉 grounding 对话的模型。从设计上看，GeoChat 不仅可以处理视觉 grounding 对话这一具有挑战性的任务，还可以执行一系列其他空间推理任务，这些任务涵盖了视觉图像理解的不同粒度级别，例如图像/区域描述、指代对象检测以及关于遥感图像的图像/区域级对话。我们下面正式概述 GeoChat 可能完成的任务。

a) 图像级对话任务。在这个任务中，GeoChat 处理一个图像 x 和一个用户文本查询 q ，其输入或输出中不包含任何特定的空间坐标。目标是进行基于对话的任务，以图像整体上下文进行，例如视觉问答 (VQA)、场景分类和图像描述。

b) 区域级对话任务。这个任务除了 x 和 q 外，还涉及向 GeoChat 提供空间框位置 b 。区域位置 b 指导模型关注图像中的特定区域，以便模型可以执行区域级描述、区域特定 VQA 或多轮对话等任务。

c) 接地对话任务。通过使用特殊标记，称为任务规范令牌 t ，GeoChat 可以被引导以不同的粒度提供对象位置，同时保持对话能力。它有助于接地图像字幕/对话、对象接地和指代表达式检测等任务。

3.1. GeoChat 架构

GeoChat 遵循 LLaVA-v1 的架构 [17]，它由三个核心组件组成，i) 全局图像编码器，ii) 一个 MLP 适配器（两个线性层）和 iii) LLM。与 LLaVA 不同，我们添加了特定的任务提示，以指示模型所需的任务类型，即接地、图像级或区域级对话。此外，我们允许输入和输出中的空间位置，使视觉提示作为输入，并在 GeoChat 输出中接地对象。值得注意的是，原始 LLaVA 模型无法执行对象接地或接受区域

Data	Size	响应格式提示
详细描述	30k	详细描述图像。
多轮对话	65k	-
复杂问题	10k	-
RSVQA-LRBEN[20]	56k	使用单个单词或短语回答问题。
NWPU-RESISC-45[5]	31.5k	
洪水网络[25]	4k	
grounding 描述	45k	[grounding] 详细描述图像。
区域标题	40k	[identify] { b_x 左侧 b_y 顶部 b_x 右侧 b_y 底部 θ }
指代表达	25k	[refer] < p > 对象 < / p >

表1. 用于训练GeoChat的指令数据。指令类型和格式已显示。我们使用306k集进行训练，并使用一个单独的12k指令集进行测试。

输入。此外，原始LLaVA无法推理遥感图像，这是通过我们的领域特定数据集实现的。我们按如下方式描述架构中的每个组件：

任务 Token: GeoChat 的独特之处在于其能够轻松切换不同类型的遥感视觉解释任务。为了消除任务之间的不确定性，我们的方法为每个任务分配一个唯一的任务身份。我们建议三种不同的任务身份 $t \in \{\text{grounding}, \text{identify}, \text{refer}\}$ ，分别用于基于实体的对话、区域标题和指代表达理解。至于视觉问答和场景分类的情况，我们直接要求模型以单个单词或短语的形式输出答案，如表1所示。我们的方法不对与视觉无关的命令使用任何任务身份 Token。这种统一的方法得到了模块化设计的支持，该设计有效地集成了空间数据，使模型在推理视觉内容时具有灵活性。

空间位置表示。我们的模型必须精确地识别引用项的空间位置，以用于基于实体的对话、指代表达生成和理解等任务。为此，我们将框位置以文本格式表示，以表达地理位置： $b = \{b_x \text{ 左侧 } b_y \text{ 顶部 } b_x \text{ 右侧 } b_y \text{ 底部} | \theta\}$ 。在这里， $b_x \text{ 左侧 } b_y \text{ 顶部}$ 表示框的左上角点，而 $b_x \text{ 右侧 } b_y \text{ 底部}$ 表示右下角坐标。角度 θ 表示边界框从下边缘的旋转角度。在区间 $[0, 100]$ 内归一化的数值用于表示 x 和 y 坐标。这种格式的区域位置用于通过模型的输入和输出来与之交互。

视觉主干。GeoChat 适配了预训练的 CLIP-ViT(L-14) 视觉主干 [28]，该主干具有的输入分辨率为 336×336 。这导致每张图像有效产生 576 个块。由于这个分辨率不足以理解遥感图像中呈现的细节（例如，小对象和对象细节），我们在基于 transformer 的 CLIP 模型中插值位置编码以与输入图像大小 [28] 相匹配 504×504 。尽管如此




图2. GeoChat的概述——第一个用于遥感的基础大型视觉语言模型。给定图像输入和用户查询，首先使用视觉主干以更高分辨率通过插值位置编码来编码块级标记。使用多层感知器（MLP）将视觉标记适应到适合输入到大型语言模型（Vicuna 1.5）的语言空间。除了视觉输入，区域位置也可以与指定用户所需任务的特定任务提示一起输入到模型中。在这种情况下，LLM可以生成与相应对象位置交错的自然语言响应。GeoChat可以执行多任务，如图顶部所示，例如场景分类、图像/区域描述、视觉问答和基础对话。

导致块的数量几乎翻倍（即每张图像1296个），这种增强的分辨率使我们能够处理更大的图像尺寸，并支持在高分辨率遥感图像中的更好视觉基础。

MLP 跨模态适配器。 从冻结的 CLIP- ViT[28], 我们将输出标记 ($\in \mathbb{R}^{1296 \times 1024}$) 具有 1024 维度投影到语言模型空间, 使用一个具有一个隐藏层的 MLP 适配器。适配器具有 1024 的输入维度, 并输出一个大小为 4096 的向量, 对应于 LLM 的输入大小 [7]。使用 GeLU [10] 作为激活函数。

大型语言模型。 开源的 Vicuna-v1.5(7B) [7] 大型语言模型被用作 GeoChat 的基础。该语言模型作为我们框架中多样化视觉-语言输入的单个接口。为了完成不同的视觉-语言任务, 我们直接依赖于 Vicuna-v1.5(7B) [7] 语言标记。我们明确与语言模型交互, 以构建边界框的文本表示, 以表达它们的空间坐标, 用于需要生成空间位置的视觉定位任务。类似地, 通过在给定输入后附加系统提示, 确保 LLM 的安全、对齐和有效行为。

[用户] <im_start> 图像特征 <im_end> [任务标识符] [助手]

图 3. GeoChat 的多任务指令模板。

基于低秩适配 (LoRA) [11] 的策略用于微调 LLM。在训练过程中, 我们没有微调预训练 Vicuna-v1.5[7], 组成权重矩阵的所有权重, 而是在 LoRA [11] 中微调两个较小的矩阵, 这些矩阵近似于原始较大的矩阵。之后, 微调的适配器被输入到预训练模型中并用于推理。LoRA 适配确保了更快的训练, 并避免了遗忘在通用自然语言指令上训练和微调的 LLM 中嵌入的原始知识。这是一个重要特性, 因为它允许模型在 GeoChat 的遥感推理框架中引入关于通用对象类型、地标和可供性的外部上下文。

3.2. 训练细节

为提升我们的模型在通用视觉任务上的效果并优化训练效率, 我们采用了一种策略, 即使用预训练权重初始化网络, 并对特定部分进行微调以远程




图4. GeoChat指令集中可用的标注类型。顶部行：对于给定的遥感图像，我们获取对象属性和关系信息、指代表达和区域描述及其相应的区域标注（显示在图像上）。底部行：这些结构化信息用于创建包含总计318k图像-指令对丰富的指令集。

相关任务[28],我们使用一个在大量文本和视觉数据上预训练的CLIP-ViT(L-14)编码器[17],在LAION-CC-SBU数据集的558K子集上预训练的MLP适配器[26]使用BLIP[15]的标题5[7]和Vicuna-v15[7]来初始化我们的模型。为使我们的模型适应遥感图像，我们随后使用LoRA[11]微调LLM，同时在训练过程中冻结MLP适配器和CLIP编码器[28]。

4. 遥感多模态指令数据集 et

通过使用 LLM Vicuna [7], 我们通过呈现和整理多样化的指令跟随数据, 包括关于遥感图像的多轮对话 (表 1), 将模型对齐到遵循一系列指令。我们特别将系统指令作为提示, 要求 Vicuna [7] 以仿佛能够可视化图像的方式生成多轮问答对 (尽管它只能访问文本)。这是通过在提示中手动组合少量上下文示例来实现的, 以向 Vicuna [7] 展示如何根据提供的标题和信息构建高质量的指令-响应对。具体来说, 从我们使用下方流程创建的简短描述中, 我们随机采样 65k 张图像来创建多轮对话, 10k 张图像来生成复杂问答, 以及 30k 张图像来为给定的简短描述生成详细描述。

在组合中, 转换为指令格式后,

我们获得了近306k个图像-指令对用于训练和12k个用于测试。接下来, 我们概述指令集创建过程。

数据集	类别	# 类别	# 图像	图像大小
DOTA	目标检测	18	17,480	1024 × 1024
DIOR	目标检测	20	23,463	800 × 800
FAIRIM	目标检测	37	64,147	600 × 600
LRBEN(rsvqa)	视觉问答	-	600	256 × 256
洪水网络 视觉问答		-	4056	3000 × 4000
NWPU-RESISC-45	场景分类	45	31,500	256 × 256

表 2. 列出了用于创建 GeoChat VLM 训练的遥感指令集的数据集。我们包含具有不同图像大小和类别类型的对象检测、视觉问答和场景分类数据集, 以确保多样性。

构成数据集: 在我们的指令集编译中, 我们整合了三种不同类型的数据集, 包括为对象检测、场景分类和视觉问答 (VQA) 设计的数据集。具体来说, 我们整合了三个对象检测 (DOTA[34], 迪奥 [6], 和 FAIRIM [27] 它们共同构成了SAMRS [30]数据集), 一个场景分类 (NWPU-RESISC-45 [5]), 一个 VQA (LRBEN[20]), 以及一个洪水检测[25]VQA数据集 (见表2)。对象检测数据集允许区域级推理能力, 因为它们提供了分割掩码和边界框。

添加缺失类别: 尽管目标检测数据库中包含了各种对象类别, 但一些重要类别如建筑物、道路、




图5. GeoChat的定性结果。(左右) 结果在 grounding、指代对象检测和灾害/损坏检测上显示。用户可以提供任务特定标记（例如，[grounding]）来根据期望行为塑造模型响应。模型可以生成文本响应(右)，仅视觉 grounding (中心) 和文本与对象 grounding 交错在一起 (左)。模型还可以指定对象类型、对象数量、对象属性和对象关系。

属性	示例
a1 类别	(e.g. “飞机, 船”)
a2 颜色	(e.g. “灰色, 白色”)
a3 相对大小	(e.g. “小, 大”)
a4 相对位置	(e.g. “右上, 底部”)
a5 关系	(e.g. “停靠在, 通过”)

表3. 列出了为对象收集的属性。属性用于获取指代表达式，例如左侧的小型飞机。

和树木是缺失的。为了解决这个问题，我们提出要利用 ViTAE-RVSA [31] 模型，该模型在LoveDA数据集上进行了预训练 [32]，该数据集包含了所需的重要类别。该模型 [31]用于在SAMRS [30] 数据集上推断这些类别，生成伪标签。为了减轻这些预测中的潜在噪声，我们移除 ViTAE-RVSA [31]的预测，这些预测我们已经从 SAMRS [30]数据集获得了真实标签，以改进结果。

属性提取：对于指代表达标注，重要的是在遥感图像中推导出各种属性。为此，我们选择了五种不同的属性类型，如表3所示。对象类别信息可以直接从SAMRS数据集获得。对于颜色提取，我们使用K均值聚类算法。具体来说，我们使用真实框从图像中提取对象的像素，并将它们聚类为 K 组。然后选择最大聚类的中心作为对象的颜色。为了指定对象的大小，我们将对象分为三种大小：小、正常和大。这种分类是通过测量整个数据集中所有类实例的面积并分配[v1]百分位数作为大标签来确定的。类似地，{v2}百分位数被指定为小尺寸，其余的归为正常类别。为了确定对象在图像中的相对位置，我们将整个图像划分为一个{v3}网格，定义了如右上、上、左上、左、中心、右、右下、左下和底部等区域。根据对象的中心像素坐标，我们相应地分配其相对位置。

类别	示例
船舶和港口（例如“锚定在, 停靠在”）	
田径场和足球场（例如“被包围, 内部”）	
车辆、桥梁、道路、环岛（例如“通过, 通过”）	
车辆和建筑物（例如“停放的”）	
机场和飞机（例如“停放的”）	
船舶和直升机停机坪	(例如“在, 包含”)

表4. 提出指令数据集中不同对象之间关系的示例。

实例，并将 80th百分位数作为大标签。类似地，20th百分位数被指定为小尺寸，其余的归为正常类别。为了确定对象在图像中的相对位置，我们将整个图像划分为一个 3×3 网格，定义了如右上、上、左上、左、中心、右、右下、左下和底部等区域。根据对象的中心像素坐标，我们相应地分配其相对位置。

为了定义给定图像中对象之间的关系，我们根据它们边界框之间的距离对不同的对象进行分组，并且对于每个子图，我们根据它们的类别标签为对象分配不同的关系。表4 展示了各种对象关系的示例。为了建立“被包围”这样的关系，我们交叉引用像素级坐标来验证一个对象是否完全包含在另一个对象内。

表达式生成：为了模拟自然语言表达，我们采用基于 [39]的预定义文本模板。短语模板包含表 {a1,..., a5} 中所示的属性 3。一组同类对象的表达式生成如下：

模型	UCMerced	AID
Qwen-VL [1]	62.90	52.60
MiniGPTv2 [4]	4.76	12.90
LLaVA-1.5 [17]	68.00	51.00
GeoChat	84.43	72.03

表5. 在AID和UCMerced数据集上的零样本场景分类准确率比较 [33] 和 [35] 数据集。与其他通用视觉语言模型相比，GeoChat表现优异。

同类对象的表达式生成如下：

”The/A $\langle a_3 \rangle \langle a_2 \rangle a_1 \langle \text{in/on the } a_4 \rangle$.”

可能缺失的属性用 $\langle \rangle$ 括起来，而属性 $\{a_2, a_3\}$ 可以按任意顺序排列。

类似地，句子模板通过 a_5 等关系属性来建立两个对象之间的连接，其结构如下：

”The/A $\langle a_i3 \rangle \langle a_i2 \rangle a_i1 a_i5 a_j1 \langle \text{in/on the } a_j4 \rangle$.”

这里，indices i 和 j 分别代表 i^{th} 和 j^{th} 对象。

视觉 grounding：尽管在自然图像领域有指代表达式数据集 [36, 37],但在遥感领域缺乏。为此，我们使用简短描述作为指代表达式，创建了三种不同类型的问答对，即 grounding图像描述、指代表达式和区域级字幕，如表1所示。

5. 实验

5.1. 实现细节

我们使用预训练的 CLIP-ViT [24], 和 LLM (Vicuna-v1.5 [7] 并应用 LoRA[11] 微调。利用 LoRA，我们通过低秩适配精炼参数 W_q 和 W_v ，在我们的实现中，指定的秩设置为 64。模型在整个过程中始终以 504 的图像分辨率进行训练。每个训练步骤都包含为各种视觉语言任务专门设计的多模态指令模板。我们使用 AdamW [21] 优化器和余弦学习率调度器来训练我们的模型。我们保持全局批大小为 144。我们分两个阶段训练模型，首先，我们使用所有数据集进行 1 个 epoch 的训练，相应地 2400 步，然后是阶段 2，我们仅在 grounding 数据集上再训练 1600 步。

5.2. 场景分类

评估数据集。对于场景分类，我们使用 AID [33]和 UCMerced [35]评估我们的模型。AID[33] 是一个从

方法	存在性比			
LLaVA-1.5[17]	55.46	68.20	59.00	62.77
Qwen-vl-Chat [1]	38.57	67.59	61.00	55.35
MiniGPTv2 [4]	55.16	55.22	39.00	54.96
RSVQA[20]	87.47	81.50	90.00	86.32
EasyToHard[38]	90.66	87.49	91.67	89.94
双模态[2]	91.06	91.16	92.66	91.63
SHRNet [40]	91.03	90.48	94.00	91.84
RSgPT[12]	91.17	91.70	94.00	92.29
GeoChat	91.09	90.33	94.00	90.70

表 6. 在 RSVQA-LRBEN [20] 数据集上，针对 VQA 任务，与通用零样本（顶部）和 RS-VQA 专用（中间）模型的比较。[1, 4, 17] 在零样本设置下进行评估。GeoChat 表现优于其他零样本模型，并与在目标数据集上专门微调的 SOTA 监督模型（如 RSGPT）具有竞争力（而我们的模型是一个通用模型，未在目标数据集上进行专门微调）。

Google Earth影像中汇编的大规模航空图像集合，包含30个类别，例如河流、密集住宅区等。图像由遥感图像解译领域的专家标注。总共，AID [33] 数据集包含30个类别中的10,000张图像。这些图像来自不同的国家以及不同的天气条件。对于评估，我们使用 AID [33] 数据集的20%进行分割。UCMerced [35]是一个土地利用场景分类数据集，包含2,100张图像和21个类别。每张图像的尺寸为 256×256 。我们使用整个 UCMerced [35] 数据集作为零样本测试集。

结果。我们用所有类别提示模型，并提示其使用单个词/短语对图像进行分类。例如，我们输入类似: ”Classify the image within one of the given classes: dense residential area ... school. Answer with one , , word or short phrase.”的提示。我们在 AID 和 UCMerced 上计算零样本准确率。GeoChat 显著优于其他 VLM，在 UCMerced 上的准确率为 84.43% [35]，在 AID [33], 上的准确率为 72.03% [7]，如表 5 所示。值得注意的是，最近的 MiniGPT-4-v2[4] 未能遵循为此特定任务提供的指令，并返回了数据集中不相关的类别。如果我们从 Vicuna- v1 传递答案，其准确率接近 5%。我们让它检查输出句子是否指代真实类别。相比之下，Qwen-VL 和 LLaVa-1.5 在指令遵循方面表现良好，但由于缺乏领域知识，未能达到 GeoChat 的水平。

5.3. 视觉问答

用于评估的数据集。RSVQA-HRBEN [20]包含 10,569 张高分辨率照片和 1,066,316 个问答对，分别分配为训练集、验证集、测试集1和测试集2，占比为 61.5%、11.2%、20.5% 和 6.8%。该数据集包含三种问题类型：存在、比较和计数。评估时，我们使用测试集2

模型	小 中		大 单多		多对象 grounding	[refer]		
MiniGPTv2 [4]	1.7	9.9	21.9	9.1	3.6	8.2	2.6	7.6
GeoChat	2.9	13.6	21.7	16.0	4.3	10.5	11.8	10.6

表7. GeoChat在我们的基准测试上的性能 (acc@0.5%) 比较。小、中和大指的是基于边界框面积的对象大小。单/多对象指的是问题要求模型预测的对象数量。 [refer]: 表中a2、a3或a4使用一个属性引用的对象3。 [grounding]: 表中a1-a5属性组合引用的对象3。总体而言，GeoChat优于基线，但在这一复杂任务上仍有显著改进空间。

模型	存在性比		
Qwen-VL[1]	66.44	60.41	63.06
LLaVA-1.5[17]	69.83	67.29	68.40
MiniGPTv2[4]	40.79	50.91	46.46
GeoChat	58.45	83.19	72.30

表8. 与其他通用ZS模型在RSVQA-HRBEN数据集上的比较 [20] 用于视觉问答。这里所有模型都没有在目标数据集上进行训练。GeoChat与通用VLMs相比表现优异。

用于 RSVQA-HRBEN [20]的数据集，包含 47k 个问答对。RSVQA-LR [20] 由 772 张低分辨率图像和 77,232 个问答对组成，分别用于训练、验证和测试，占比为 77.8%、11.1% 和 11.1%。问题分为四类：存在、比较、农村/城市和计数。在评估时，我们排除了区域和计数问题，因为答案为数值型且可量化为多个类别。例如，在 RSVQA-LRBEN [20] 数据集中，计数问题被量化为五个类别：0、1-10、11-100、101-1000 和大于 1000。评估时，我们使用 RSVQA-LRBEN [20] 的测试集，包含 7k 个问答对。

结果。 为了将答案约束为简单的yes/no，以及针对农村/城市问题类型，我们在每个问题的末尾添加了一个合适的提示。GeoChat在RSVQA-LRBEN测试集上接近SOTA专业模型，该模型是RSGPT [12]，在目标数据集上微调了5次进行比较。我们还匹配了城市-农村分类子集的SOTA，如表 6所示。对于 RSVQA-HRBEN，GeoChat在零样本设置下的平均准确率比其他VLM高3.9%，同时在LLaVA-v1.5上比较子集高15.9%[17],如表 8所示。

5.4. 视觉 grounding

用于评估的数据集。 为了评估定位任务，我们提出一个新的基准，其中包含不同的指称和定位任务。我们使用了来自 [30] 的数据集，并使用了与第 4节中相同的 dataset 创建流程来构建测试基准。总共有 7653 [指称]，758 [定位]，555 个指称和定位描述问题。我们使用准确率@0.5 作为评估指标。如果预测框与真实框的交并比 (IoU) 超过 0.5，则计算准确率。

模型	acc@0.5	acc@.25	METEOR
MiniGPTv2[4]	10.8	30.9	16.4
GeoChat	11.7	33.9	48.9

表 9. grounding 描述任务的结果。

模型	ROUGE-1		
MiniGPTv2[4]	32.1	31.2	10.0
GeoChat	87.3	87.2	83.9

表10. 区域级字幕性能。

真实框超过 0.5 IoU 的重叠。

结果。 表 7 显示了我们的方法和 MiniGPT-4-v2 [4]在所提出的基准上的性能。总体而言，**模型在小对象上或需要预测多个边界框时性能较低。**与 MiniGPT-4- v2[4], 相比，我们的模型在**中等尺寸图像上表现更好。**在 grounding 描述任务中，我们计算了作为**多个边界框生成的 IoU 以及生成的文本答案。**我们的模型提供了更好的描述，其边界框准确率略优于 MiniGPT-4-v2[4] (表9)。至于区域级字幕，我们基于与真实区域级字幕的文本准确率评估了两个模型 (表 10)。我们的模型在 ROUGE 和 METEOR 分数方面显著优于 MiniGPT-4-v2。

6. 结论

尽管大型视觉语言模型 (VLMs) 在**自然图像领域**取得了最近的进展，但由于独特的领域特定挑战，它们在**遥感 (RS) 场景**中的性能仍然有限。为了弥补这一差距，我们提出了GeoChat，这是第一个在多任务对话能力方面表现出色的遥感VLM，能够处理高分辨率RS图像。**GeoChat不仅回答图像级查询，还参与特定区域的对话，用精确的空间坐标来定位响应。**我们创建了一个新的遥感多模态指令跟随数据集，其中包含 318k图像-指令对，并具有多样化的多任务格式。GeoChat在各种遥感任务中实现了稳健的零样本性能，包括场景分类、VQA、多轮对话、视觉定位和指代对象检测，从而建立了一个全面的基准。

参考文献

- [1] 金泽白, 帅白, 舒生杨, 世杰王, 思南谭, 彭王, 俊阳林, 长周, 和景仁周。Qwen-vl: 一个具有多功能能力的前沿大型视觉语言模型。arXiv预印本arXiv:2308.12966, 2023年7月, 8月[2]雅库布·巴齐, 穆罕默德·马哈茂德·阿尔·拉哈尔, 穆罕默德·拉明·梅哈菲, 曼苏尔·阿卜杜拉齐兹·阿尔·祖尔, 和法里德·梅尔加尼。基于双模Transformer的方法, 用于遥感图像中的视觉问答。地球科学和遥感IEEE交易, 60卷11期, 2022年1月7日: -。[3] 克里斯特林·查皮斯, 瓦莱丽·泽马滕, Sylvain Lobry, 贝尔特朗·勒·索, 和Devis Tuia。Prompt-rsvqa: 向语言模型提示视觉上下文, 用于遥感视觉问答。IEEE/CVF计算机视觉与模式识别会议论文集, 2022年, 第1372-1381页。2 [陈俊, 朱德耀, 沈晓倩, 李翔, 哲春刘, 鹏川张, 拉格鲁拉曼·克里希南莫orthy, 维卡斯·钱德拉, 云阳熊, 和穆罕默德·埃尔霍西尼。Minigpt-v2: 大型语言模型作为视觉语言多任务学习的统一接口。arXiv预印本arXiv:2310.09478, 2023年7月, 8月[4] 龚程, 俊伟韩, 和陆晓强。遥感图像场景分类: 基准和最新技术。IEEE汇刊, 105卷10期: 1865-1883页, 2017年2月, 3月, 5月[5] 龚程, 王加宝, 李科, 谢兴兴, 冷波朗, 姚岩庆, 和俊伟韩。无锚定向提议生成器, 用于目标检测。地球科学和遥感IEEE交易, 60卷1-11页, 2022年5月。[6] 魏林蒋, 朱汉李, 子林, 英生, 吴张浩, 浩张, 连民郑, 思远庄, 庄永浩, 约瑟夫·E·冈萨雷斯, 伊昂·斯托伊卡, 和埃里克·P·兴。Vicuna: 一个开源聊天机器人, 以90%* chatgpt质量令人印象深刻, 2023年2月, 4月, 5月, 7月[7] 文亮戴, 俊楠李, 东旭李, 安东尼·孟·华·张, 俊奇赵, 伟生王, 伯阳李, 帕斯卡尔·冯, 和史蒂文·黄。Instructblip: 朝着具有指令微调的通用视觉语言模型发展, 2023年2月[8] Alexey Dosovitskiy, 卢卡斯·贝耶, 亚历山大·科列斯尼科夫, 迪尔克·魏森博恩, 晓华翟, 托马斯·翁特廷纳, 莫斯塔法·德赫加尼, 马蒂亚斯·明德纳, 乔治·海格尔德, Sylvain Gelly, 雅各布·乌斯克雷特, 和尼尔·豪尔斯比。一幅图像值16x16个词: 用于大规模图像识别的Transformer。ICLR, 2021年2月[9] 丹·亨德里克斯和凯文·吉普尔。高斯误差线性单元 (gelus)。arXiv预印本arXiv:1606.08415, 2016年4月[10] 爱德华·J·胡, 一朗沈, 菲利普·沃尔里斯, Zeyuan Allen-Zhu, 元智李, 肖安王, 陆王, 和伟竹陈。LoRA: 大型语言模型的低秩适应。国际学习表示会议, 2022年2月, 4月, 5月, 7月[11] 元胡, 建龙袁, 聪聪温, 晓南陆, 和李翔。Rsgpt: 一个遥感视觉语言模型以及基准。arXiv预印本arXiv:2307.15266, 2023年。1, 2, 7, 8[13] Bo Li, Yuanhan Zhang, Liangyu Chen, Jinghao Wang, Jingkang Yang, 和 Ziwei Liu。Otter: 一个具有上下文指令微调的多模态模型。arXiv预印本arXiv:2305.03726, 2023年。2[14] Chunyuan Li, Cliff Wong, Sheng Zhang, Naoto Usuyama, Haotian Liu, Jianwei Yang, Tristan Naumann, Hoifung Poon, 和 Jianfeng Gao。Llava-med: 在一天内训练一个用于生物医学的大型语言和视觉助手。arXiv预印本arXiv:2306.00890, 2023年。2[15] Junnan Li, Dongxu Li, Caiming Xiong, 和 Steven Hoi。Blip: 通过语言 - 图像预训练进行统一的视觉语言理解和生成。在国际机器学习会议中, 第12888-12900页。PMLR, 2022年。5[16] Xiang Li, Congcong Wen, Yuan Hu, 和 Nan Zhou。Rs-clip: 通过对比视觉语言监督进行零样本遥感场景分类。国际应用地球观测与地理信息杂志, 124 103497, 2023 2:。[17] Haotian Liu, Chunyuan Li, Yuheng Li, 和 Yong Jae Lee。具有视觉指令微调的改进基线。arXiv预印本arXiv:2310.03744, 2023年。2, 3, 5, 7, 8[18] Haotian Liu, Chunyuan Li, Qingyang Wu, 和 Yong Jae Lee。视觉指令微调。arXiv预印本arXiv:2304.08485, 2023 2:。[19] Haotian Liu, Chunyuan Li, Qingyang Wu, 和 Yong Jae Lee。视觉指令微调, 2023年。1, 2[20] Sylvain Lobry, Diego Marcos, Jesse Murray, 和 Devis Tuia。Rsvqa: 用于遥感数据的视觉问答。地球科学和遥感 IEEE 交易, 58 (12):8555-8566, 2020年。2, 3, 5, 7, 8[21] Ilya Loshchilov 和 Frank Hutter。解耦权重衰减正则化。arXiv预印本arXiv:1711.05101, 2017年。7[22] Muhammad Maaz, Hanoona Rasheed, Salman Khan, 和 Fa-had Shahbaz Khan。Video-chatgpt: 通过大型视觉和语言模型实现详细视频理解。arXiv预印本arXiv:2306.05424, 2023年。2[23] OpenAI。Gpt-4技术报告, 2023年。1[24] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, 等。从自然语言监督中学习可转移的视觉模型。在国际机器学习会议中, 第8748-8763页。PMLR, 2021年。7[25] Maryam Rahnemounfar, Tashnim Chowdhury, Argho Sarkar, Debvrat Varshney, Masoud Yari, 和 Robin Murphy。Floodnet: 用于洪水后场景理解的高分辨率航空影像数据集。arXiv预印本arXiv:2012.02951, 2020年。3, 5[26] Christoph Schuhmann, Richard Vencu, Romain Beaumont, Robert Kaczmarczyk, Clayton Mullis, Aarush Katta, Theo Coombes, Jenia Jitsev, 和 Aran Komatsuzaki。Laion-400m: clip过滤的4亿图像-文本对开放数据集。arXiv预印本arXiv:2111.02114, 2021年。5

[27] Xian Sun, Peijin Wang, Zhiyuan Yan, Feng Xu, Ruiping Wang, Wenhui Diao, Jin Chen, Jihao Li, Yingchao Feng, Tao Xu, Martin Weinmann, Stefan Hinz, Cheng Wang, 和 Kun Fu. Fair1m: 用于高分辨率遥感影像中细粒度目标识别的基准数据集。IS-PRS摄影测量与遥感杂志, 184: 116–130, 2022年。5[28] Yi Tay, Minh C Phan, Luu Anh Tuan, 和 Siu Cheung Hui. 使用全息双lstm架构学习排序问答对。在40届国际ACM SIGIR信息检索研究与发展会议论文集中, 第695–704页。ACM, 2017年。3, 4, 5[29] Omkar Thawkar, Abdelrahman Shaker, Sahal Shaji Mul-lappilly, Hisham Cholakkal, Rao Muhammad Anwer, Salman Khan, Jorma Laaksonen, 和 Fahad Shahbaz Khan. Xraygpt: 使用大型医疗视觉语言模型进行胸部X光片摘要。arxiv: 2306.07971, 2023年。2[30] Di Wang, Jing Zhang, Bo Du, Dacheng Tao, 和 Liangpei Zhang. 使用分割一切模型扩展遥感分割数据集。在arxiv中, 2023年。2, 5, 6, 8 [31] Di Wang, Qiming Zhang, Yufei Xu, Jing Zhang, Bo Du, Dacheng Tao, 和 Liangpei Zhang. 推进普通视觉Transformer向遥感基础模型。地球科学和遥感 IEEE 交易, 61 15, 2023年1月6日: –。[32] Junjue Wang, Zhuo Zheng, Ailong Ma, Xiaoyan Lu, 和 Yanfei Zhong. LoveDA: 用于领域自适应语义分割的遥感土地覆盖数据集, 2021年。6[33] Gui-Song Xia, Jingwen Hu, Fan Hu, Baoguang Shi, Xiang Bai, Yanfei Zhong, Liangpei Zhang, 和 Xiaoqiang Lu. Aid: 用于航空场景分类性能评估的基准数据集。地球科学和遥感 IEEE 交易, 55(7):3965–3981, 2017年。7[34] Gui-Song Xia, Xiang Bai, Jian Ding, Zhen Zhu, Serge Be-longie, Jiebo Luo, Mihai Datcu, Marcello Pelillo, 和 Liang-pei Zhang. Dota: 用于航空图像中目标检测的大规模数据集。在IEEE计算机视觉与模式识别会议 (CVPR) 中, 2018年。5[35] Yi Yang 和 Shawn Newsam. 视觉词袋和空间扩展用于土地利用分类。在第18届SIGSPATIAL地理信息系统国际会议论文集中, 第270–279页, 2010年。7[36] Peter Young, Alice Lai, Micah Hodosh, 和 Julia Hocken-maier. 从图像描述到视觉指称: 事件描述语义推理的新相似度度量。计算语言学协会交易, 2:67–78, 2014年。7[37] Licheng Yu, Patrick Poirson, Shan Yang, Alexander C Berg, 和 Tamara L Berg. 在指称表达式中建模上下文。在计算机视觉-ECCV 2016: 第14届欧洲会议, 阿姆斯特丹, 荷兰, 10月11日–14日, 2016年, 第14, 69 85页。Springer, 。7[38] Zhenghang Yuan, Lichao Mou, Qi Wang, 和 Xiao Xiang Zhu. 从易到难: 学习用于遥感数据视觉问答的语言指导课程。地球科学和遥感 IEEE 交易, 60: 1–11, 2022年。2, 7

[39] 杨赞, 熊志通 和 袁袁. Rsvg: 探索遥感数据上的视觉 grounding 数据和模型。地球科学和遥感 IEEE 交易, 61: 1–13, 2023. 6[40] 张子潇, 焦立成, 李玲玲, 刘旭, 陈不华, 刘方, 李宇轩 和 郭志成. 遥感视觉问答的空间层次推理网络。地球科学和遥感 IEEE 交易, 61:1–15, 2023. 2, 7[41] 朱德耀, 陈俊, 沈晓倩, 李翔 和 Mohamed Elhoseiny. MiniGPT-4: 使用高级大型语言模型增强视觉语言理解。arXiv 预印本 arXiv:2304.10592, 2023. 2[42] 乌斯曼·齐亚, M·穆罕默德·里亚兹 和 阿卜杜勒·加富尔. 将遥感图像转换为文本描述。应用地球观测与地理信息国际杂志, 108:102741, 2022. 2