

SpaceMind: 一个模块化和自进化的具身视觉语言智能体框架，用于自主在轨服务

吴奥迪^{1,2} 韩浩东^{1,2} 罗旭波^{1,2} 王瑞索² 何山² 万雪^{2*}

¹中国科学院大学，北京，中国 ²中国科学院空间应用技术工程中心，北京，中国

摘要

自主在轨服务需要能够通过视觉传感器感知三维空间情况、执行多阶段任务的具身智能体。我们提出了SpaceMind，一个模块化和自进化的视觉语言模型（VLM）智能体框架，将知识、工具和推理分解为三个独立可扩展的维度：带动态路由的技能模块、具有可配置配置的模型上下文协议（MCP）工具和可注入的推理模式技能。MCP-Redis接口层使得同一代码库可以在模拟和物理硬件之间无需修改地运行，而技能自进化机制将操作经验提炼为持久的技能文件，无需模型微调。我们通过在五个卫星、三种任务类型和两个环境（一个UE5模拟和一个物理实验室）中进行的192次闭环运行验证了SpaceMind，故意包括退化条件以测试鲁棒性。在标称条件下，所有模式都实现了90-100%的导航成功；在退化情况下，前瞻模式在搜索和接近任务中唯一成功，而其他模式失败。一项自进化研究表明，智能体在六个组中的四个组从单个失败事件中恢复，包括从完全失败到100%成功的完整恢复，以及检查分数从12提高到100分。实际验证确认了零代码修改的物理机器人转移，实现了100%的会合成功。代码：<https://github.com/wuaodi/SpaceMind>。

1 简介

随着近地轨道空间碎片的日益增多和卫星的老化，截至 2023 [1]，已有超过20,000个已编目物体，在轨服务、组装和制造（OSAM）已成为一项日益关键的能力 [2, 3]。NASA的OSAM-2 [4]、欧洲航天局的ClearSpace-1 [5]，以及RemoveDEBRIS [6] 等任务已展示了主动碎片清除和卫星寿命延长的早期概念。然而，当前的操作方法依赖于为已知合作目标设计的预编程序列，限制了它们处理真实在轨遭遇中多样化和不可预测条件的能力。近期研究开始探索将视觉语言模型（VLMs）作为航天器操作代理 [7, 8]，表明大型基础模型可以通过自然语言推理分解复杂的太空任务。然而这些努力

*Corresponding author. Email: wuaodi20@mails.ucas.ac.cn (吴奥迪), wanxue@csu.ac.cn (万雪).



图1: SpaceMind概述。该框架作为基于视觉语言模型的决策控制中心运行，通过视觉传感器感知、推理当前情况并发布运动和传感器控制命令。它支持三种任务类型，即会合、搜索与接近和检查，这些任务类型在高保真UE5模拟（5颗卫星和174次运行）和物理实验室（2颗卫星和18次运行）中均得到支持。关键能力包括模块化技能路由、即插即用工具、可切换的推理模式以及经验驱动的自我进化。

仍处于演示阶段，通过读取屏幕文本在简化的游戏环境中运行，而不是处理实际视觉传感器数据，仅使用整体式提示处理单个任务，并且缺乏跨目标或环境的系统评估。更广泛地说，当前AI智能体研究格局 [9] 主要受数字世界应用（如网页导航、代码生成和对话系统）或简单物理场景（如桌面操作和室内导航）的支配。相比之下，自主在轨服务要求具身化智能体，通过真实传感器感知，在物理3D环境中执行6自由度（DoF）运动控制，并持续执行跨越数十个决策步骤的多阶段任务，从

远距离搜索到近距离接近再到细粒度诊断（图1）。如何为该领域构建一个可扩展、可适应的传感器驱动智能体框架仍然是一个开放的问题。

构建这样的框架涉及四个相互关联的挑战。首先，目前还没有为太空操作设计的模块化智能体架构。现有的太空智能体原型将所有任务知识编码在一个单体提示中，随着任务数量的增加，这变得难以维护；模拟和真实硬件通常需要独立的代码库，而没有接口抽象来连接它们。其次，太空智能体缺乏灵活的推理深度和跨步记忆。不同的任务复杂性需要不同的决策深度；一个简单的会合可能只需要直接动作选择，而一个搜索和接近任务则受益于深思熟虑的多候选评估。然而，当前方法没有切换推理策略的机制。此外，智能体需要在决策步骤之间具有持久记忆，以从目标丢失中恢复并动态调整策略，而现有的太空智能体设计不支持这一点。第三，太空智能体无法从经验中改进。当前设计是一次性执行器，每个场景都从零开始，放弃了先前运行中获得的操作知识。太空操作本质上是指重复执行场景，其中相同的任务类型在不同的目标和条件下重复出现；一个积累经验的智能体可以显著提高长期可靠性。传统适应方法不适用于在轨部署：微调需要标记数据和梯度更新，强化学习需要显式奖励函数设计，而情境学习受限于上下文窗口，并且不会跨会话持久化。第四，太空智能体架构背后的设计决策缺乏系统的经验验证。先前研究 [7, 8] 报告了单个任务的结果，只有少量运行，没有证据表明模块化架构是否可扩展，应该选择哪种推理模式，自我进化是否有效，或者相同的架构是否可以跨环境迁移。

为应对这些挑战，我们提出了 SpaceMind，一个模块化和自我进化的具身 VLM-智能体框架，用于自主在轨服务（图2）。SpaceMind 使用 VLM 作为决策-控制中心，通过视觉传感器感知环境，推理当前情况，调用专用工具，并发布运动指令。其设计包含四个渐进式层次。为应对模块化挑战，SpaceMind 将智能体知识分解为独立技能模块，通过基于 LLM 的动态路由，通过模型上下文协议（MCP）[10] 暴露所有可执行工具，并通过可注入的模式技能切换推理模式。这三个正交维度通过单一声明式配置进行管理。Redis 消息总线将智能体与物理后端解耦，允许同一代码库在模拟和真实硬件上无需修改即可运行。为应对推理挑战，SpaceMind 在同一架构中托管三种推理模式：标准模式用于直接决策，ReAct [11] 用于迭代思维-行动-观察循环，以及前瞻模式用于多候选预测和选择。这些模式得到了分层记忆系统的补充，该系统维护最近的步骤详情和长期的压缩摘要。为应对经验积累挑战，技能自进化机制使智能体能够反思每个完成的场景，将操作经验提炼为结构化学习技能文件，并自动注入后续运行中，从而在不修改模型权重的情况下积累持久、可审计的知识。最后，为应对验证挑战，我们在五颗卫星、三种任务类型、三种推理模式、三种初始条件和两种环境中进行了总计192次运行的闭环实验，即高保真UE5模拟和物理实验室。

实验得出了一些可操作的发现。一项包含9次运行的工具消融研究表明，移除激光雷达距离感知会导致导航失败，验证了模块化工具配置机制。一项涵盖135次运行、在标称和退化初始条件（如曝光不足和位置偏移）下的系统推理评估显示，所有模式均达到90-100%。

实验得出若干可操作的发现。一项包含9次运行的工具消融研究表明，移除激光雷达距离感知会导致导航失败，验证了模块化工具配置机制。一项跨越135次运行的系统推理评估，在标称和退化初始条件（如曝光不足和位置偏移）下进行，揭示所有模式在标称条件下均实现90-100%的导航成功，但在分别考察会合和搜索与接近时，表现出显著不同的退化模式：标准模式即使在退化条件下仍保持100%的会合成功，但其搜索成功率降至零。前瞻模式是唯一在退化条件下仍保持搜索成功的模式，而ReAct的快速终止策略在不良可见性下对检查有利。这些发现为部署提供了具体的模式选择指南。一项覆盖6个组共30次运行的自进化研究表明，6个组中有4个组实现了显著正向增益。最值得注意的是，一个组从完全失败恢复到100%成功，另一个组将其检查分数从100分中的12分提高到59分，两种情况下均通过从单个失败事件中学习技能实现。18次运行的现实世界验证证实，相同的代理代码库、技能定义和工具签名无需零代码修改即可操作物理移动机器人，实现100%的会合成功，并展现出跨环境的涌现规模适应性和行为一致性。

本文的贡献总结如下：

1. **用于在轨服务的模块化智能体架构。** 我们提出了SpaceMind，一个为自主航天器操作量身定制的VLM-智能体框架，它将智能体知识、工具和推理分解为三个独立可扩展的维度，即具有动态路由的技能模块、具有可配置配置文件的基于MCP的工具以及可注入的推理模式技能。一个环境无关的接口层使得相同的代码库能够在高保真航天模拟和物理实验室中无缝运行，无需修改。
2. **用于多阶段航天任务的多模式推理。** 我们在统一架构中实现了三种可切换的推理模式：标准、ReAct和前瞻性，为从简单的会合到退化条件下的长期搜索与接近任务提供可配置的认知深度。一个分层记忆系统支持跨步上下文推理，用于目标丢失恢复和跨长时间段的策略调整。
3. **用于自主在轨改进的技能自进化。** 我们引入了一种机制，使智能体能够在每次服务场景后自主地将操作经验提炼为持久、结构的技能文件，而无需模型微调或奖励函数设计，在六个实验组中的四个组中实现了显著的失败恢复。
4. **全面的闭环验证。** 我们对基于VLM的航天智能体进行了首次系统评估，跨越了五颗卫星、三项任务、三种推理模式和两个互补环境，为每个架构设计决策提供了实证基础。

2 相关工作

2.1 自主航天器操作与基于VLM的航天智能体

自主在轨服务传统上依赖于针对已知合作目标的预编程序列，感知由专用管道处理航天器检测 [12]，部件级语义分割 [13, 14]，和相对姿态估计 [15–17]。这些方法近年来取得了显著进展，如Pauly等人所综述 [18]，但它们作为孤立模块运行，必须手动集成到特定任务的控制流程中，限制了它们对新型目标或任务的适应性。

近期的研究工作开始探索大型语言和视觉语言模型作为高级航天器操作员。Rodriguez-Fernandez 等人 [7]证明了语言模型可以

通过自然语言推理分解航天器控制任务，而卡拉斯科等人 [8]将其扩展到视觉语言模型用于操作员级决策。然而，这些研究存在三个关键局限性。它们使用单体提示和没有模块化框架来处理单个任务，从而无法实现多任务可扩展性。它们通过读取屏幕文本和用户界面元素在简化的游戏环境中运行，而不是处理实际视觉传感器数据，使其成为基于文本的代理而非真正具身化、传感器驱动的系统。此外，它们还报告了少量运行结果，且没有进行跨环境验证。另外，富特等人 [19] 探索了适配基础模型用于火星表面导航，但没有闭环控制或多任务评估。相比之下，SpaceMind 通过模块化架构处理原始RGB相机和LiDAR数据，在既高保真UE5模拟又物理实验室中运行，并在跨越五种卫星目标和三种任务类型的192次闭环运行中进行了验证。

2.2 基于LLM/VLM的具身智能体与工具集成

更广泛的AI智能体社区在大型基础模型周围构建自主系统方面取得了快速进展。王等人 [9] 调查了基于LLM的智能体新兴范式，该范式包括语言模型核心、记忆、工具使用和规划能力。在工具集成方面，秦等人 [20] 形式化了使用基础模型的工具学习框架，而模型上下文协议（MCP） [10] 为连接智能体到外部工具和数据源提供了标准化接口。思维链提示 [21] 表明，明确的中间推理步骤显著提高了LLM决策质量，而思维树 [22] 将这一思想扩展到对多个推理分支的刻意搜索。ReAct [11] 进一步引入了将推理轨迹与工具动作交错进行的有影响力的模式，使智能体能够基于环境反馈做出决策。

在具身环境中，PaLM-E [23]展示了基于机器人观测的多模态推理，SayCan [24] 和内心独白 [25] 通过环境反馈实现了语言引导的工具使用，而视觉 - 语言 - 动作（VLA）模型如 RT-2 [26] 和OpenVLA [27]已展示了用于机器人操作的端到端视觉运动控制。GPT-Driver [28] 将基于LLM的规划应用于自动驾驶。这些方法主要针对任务范围相对较短、低维动作空间（例如桌面抓取、车道跟随）的陆地环境。当将这一范式扩展到太空作业时，仍有三个差距。这些系统都没有解决非结构化3D环境中的6自由度长时程任务。大多数采用单一、固定的推理策略，没有对替代推理模式的系统性比较。此外，工具集成通常是针对特定环境硬编码的，缺乏跨环境可移植性所需的抽象层。SpaceMind通过将智能体与物理后端解耦的MCP-Redis接口架构、具有基于LLM的动态路由的模块化技能层（取代了整体式提示）以及三个系统性地135次运行中评估的可切换推理模式来解决这些差距。

2.3 经验驱动自我改进

使智能体能够从部署经验中自我改进是一个长期目标。现有的适应范式在太空操作环境中都存在显著局限性。微调需要标记训练数据和梯度计算，这在轨道上都不切实际。标准情境学习受限于上下文窗口，并且不会跨会话持续。检索增强生成（RAG）检索现有文档，但无法从经验中合成新的操作知识。强化学习需要显式奖励函数设计，并且在物理环境中样本效率低下。

并且样本效率低下。

近期有数项研究探索了语言智能体的轻量级自我改进机制。Reflexion [29] 引入了语言强化学习，其中智能体反思其失败并存储文本反馈以供后续试验使用。然而，这些反思仍保留在上下文窗口中，并在会话间丢失。ExpeL [30] 从轨迹中提取可重用的“经验”并将其存储为持久性洞察，但提取的知识仍为自然语言摘要，缺乏结构化格式或质量验证。Voyager [31] 通过在 Minecraft 中生成可执行代码函数构建了一个持久技能库，这代表了与我们方法最接近的概念性先例；但它运行在一个具有确定性物理的数字沙盒中，其技能是代码片段而非可审计或与现有领域专业知识组合的结构化操作知识。

SpaceMind 的技能自进化机制占据了一个独特的领域：它从物理世界空间任务中的真实部署经验生成持久、结构化、可审计的操作知识。学习到的技能与手写技能具有相同的格式，能够无缝集成到模块化技能架构中并由技能网关自动路由。与 Reflexion 不同，知识在会话间持久存在；与 Voyager 不同，它针对具有安全关键约束的物理 3D 操作，并包括带指纹去重的质量门、安全短语过滤和任务范围绑定以防止跨任务污染。在六组 30 次运行中的实验验证表明，四组实现了显著改进，该机制在从失败中恢复和迭代改进感知策略方面特别有效。

3 方法论

3.1 系统概述

SpaceMind 是一个闭环具身智能体框架，其中视觉语言模型（VLM）作为中央决策控制中心。图2说明了整体架构。在每个决策步骤 t ，智能体从环境中接收一个观察 o_t ，该观察由一个 RGB 图像和一个可选的 LiDAR 距离摘要组成。通过组合动态路由的技能模块、推理模式指令和分层记忆上下文（总结先前的步骤）来组装系统提示。VLM 处理此提示，并结合视觉观察，以工具调用（例如，设置_位置，设置_姿态，设置_曝光）的形式生成动作 a_t ，该动作通过模型上下文协议（MCP）[10] 分发，并通过 Redis 消息总线转发到物理环境。环境执行该动作，生成新的观察 o_{t+1} ，然后循环继续，直到达到终止条件。形式上，每个步骤的决策过程为

$$a_t = \pi_{\text{VLM}}(o_t, \mathcal{S}_t, \mathcal{M}_t; \theta), \quad (1)$$

其中 $\mathcal{S}_t$ 表示组装的技能提示（由技能网关的路由结果确定）， $\mathcal{M}_t$ 表示分层记忆上下文， θ 表示冻结的 VLM 参数。环境转换遵循

$$o_{t+1} = \mathcal{E}(o_t, a_t), \quad (2)$$

where $\mathcal{E}$ 抽象了物理后端（UE5 模拟或实验室硬件），通过 Redis 消息总线与智能体解耦。

该架构围绕四个设计层组织，每个层针对第1节中确定的一个特定挑战。具有动态路由的技能层通过将智能体知识分解为可独立组合的技能模块来解决模块化挑战（第3.2节）。The




图2: SpaceMind架构。该框架包含四个层次。技能层将智能体知识分解为基于LLM的动态路由的模块化技能定义（第3.2节）。VLM决策核心包含三种可切换的推理模式，具有分层内存（第3.3节）。MCP工具层和Redis消息总线提供环境无关接口，使相同代码库能够在UE5模拟和物理实验室中运行（第3.4节）。一个侧环实现了技能自进化，它将场景经验提炼为学习技能文件，并将其注入后续运行（第3.5节）。

推理和记忆层通过托管三种可切换的推理模式和分层记忆系统来解决认知深度挑战（第3.3节）。接口和通信架构通过MCP工具抽象和Redis消息总线来解决跨环境可移植性问题（第3.4节）。技能自进化机制通过从部署场景中生成持久学习技能来解决经验积累问题（第3.5节）。

算法1总结了单个场景的完整执行流程，为以下小节中详细描述四个层次提供了统一视图。

3.2 技能层和动态路由

现有的用于太空操作的基于VLM的智能体方法将所有任务知识编码在一个单体系统提示中，当操作范围扩展时，这会引发三个问题：随着更多任务的添加，提示变得难以管理，共享策略（例如，距离相关步长调整、目标丢失恢复）无法跨任务重用，并且在操作期间积累的经验没有结构化的容器进行存储。为了解决这些限制，SpaceMind将智能体知识分解为独立的技能模块，并根据任务上下文动态路由它们。

每个技能是一个自包含的知识单元，由结构化的头部和自然语言主体组成。

算法1SpaceMind 执行集

输入: 任务描述 d , 推理模式 m , 工具配置 $\mathcal{P}$, 技能目录 $\mathcal{C}$, 最大步数 T

输出: 轨迹 τ , 结果 r

```
// 第一阶段: 初始化
( $s_{\text{task}}, S_{\text{helper}}$ )  $\leftarrow$  SkillGateway( $d, \mathcal{P}, m, \mathcal{C}$ )
2:  $\mathcal{S} \leftarrow S_{\text{core}} \cup \{s_{\text{task}}\} \cup S_{\text{helper}} \cup \text{模式技能}(m) \cup \text{已学技能}(d)$ 
3:  $\mathcal{M}_0 \leftarrow \emptyset$ ;  $o_0 \leftarrow \mathcal{E}.\text{重置}()$ 
// 第二阶段: 决策循环
4: 对于  $t = 0, 1, \dots, T-1$  执行
5:   如果  $m = \text{标准}$  则
6:      $a_t \leftarrow \pi_{\text{VLM}}(o_t, \mathcal{S}, \mathcal{M}_t; \theta)$  ▷ 公式 (1)
7:   否则如果  $m = \text{ReAct}$  则
8:      $a_t \leftarrow \text{ReActLoop}(o_t, \mathcal{S}, \mathcal{M}_t, R=3)$ 
9:   否则如果  $m = \text{前瞻性}$  则
10:     $\{c_1, c_2, c_3\} \leftarrow \text{VLM计划}(o_t, \mathcal{S}, \mathcal{M}_t)$ 
11:     $a_t \leftarrow \text{VLM选择}(\{c_1, c_2, c_3\}, o_t)$ 
12:   end if
13:   结果  $\leftarrow \text{MCP.Execute}(a_t)$  ▷ 通过Redis调用工具
14:    $o_{t+1} \leftarrow \mathcal{E}.\text{Observe}()$ 
15:    $\mathcal{M}_{t+1} \leftarrow \text{更新内存}(\mathcal{M}_t, a_t, \text{结果 } o_{t+1})$ 
16:   if 是否终止( $a_t, \text{结果}$ ) then break
17:   end if
18: 结束for
// 阶段3: 剧集后自我进化
19:  $\tau \leftarrow \text{收集轨迹}()$ ;  $r \leftarrow \text{评估}(\tau)$ 
20:  $\text{mut} \leftarrow \text{VLM反射}(\text{Summarize}(\tau, r), \mathcal{S}, \text{历史})$ 
21: if  $\text{mut} \neq \text{无变化}$  and  $\text{质量门}(\text{mut})$  then
22:    $S_{\text{learned}} \leftarrow S_{\text{learned}} \cup \text{具体化}(\text{mut})$ 
23: end if
24: 返回  $\tau, r$ 
```

头部声明技能的名称、类别、一个描述其适用性的路由摘要以及用于目录匹配的路由关键字。主体包含操作指令, 这些指令将原封不动地注入VLM系统提示中。技能被组织成一个三级分类体系:

- **核心技能**始终处于激活状态, 并为所有任务提供基础操作知识, 包括坐标约定、安全约束和一般动作策略。
- **任务技能**编码特定任务类型(例如, 会合、搜索-接近、检查)的主要策略。每个场景中恰好选择一个任务技能。
- **辅助技能**提供辅助策略, 以补充主要任务技能, 例如距离相关步长衰减、目标丢失恢复程序或多模态感知 workflows。每个场景中选择零到两个辅助技能。

一个技能网关在每个场景开始时执行动态路由。网关将当前任务描述、活动工具配置文件和推理模式作为输入, 并在可用任务和辅助技能目录上发出轻量级LLM调用。LLM选择一个主要任务

技能和最多两个辅助技能，并提供其选择的自然语言理由。如果路由调用失败（例如，由于格式错误输出），网关回退到框架配置中声明的默认技能组合，确保鲁棒性。

除了任务技能和辅助技能外，模式技能提供推理模式特定指令（详见第3.3节）。这些指令基于活动推理模式注入，并且与任务技能完全解耦，因此任何任务技能和推理模式的组合都可以无干扰地组合。自我进化机制（第3.5节）生成的技能与手写技能具有相同的格式，可以通过相同的路由管道无缝注入。

最终的系统提示通过按顺序连接活动核心技能、路由的任务和辅助技能、模式特定技能以及任何适用的学习技能来组装。所有技能分配、工具配置、推理模式和网关参数都通过单个声明式配置文件进行管理，实现四维解耦：任何任务、推理模式、工具集和技能组合都可以在不修改代码的情况下指定。

3.3 推理模式与记忆

不同的操作场景需要不同级别的认知深度。与可见目标进行简单的会面可能只需要直接动作选择，而在不良可见性下导航或搜索视野外目标则受益于深思熟虑的多步推理。SpaceMind通过在同一架构中托管三种推理模式来解决这一问题，形成可按场景选择的认知深度梯度。

标准模式 VLM接收当前观察结果、组装的系统提示以及可用工具列表，并直接生成一个工具调用作为其动作。如果选中的工具是感知操作（例如图像分析或分割），其结果可以触发后续的VLM调用，以在同一步骤内选择后续的运动动作。该模式产生的计算开销最低，适用于仅从当前观察结果即可确定正确动作的任务。

ReAct模式 遵循ReAct范式 [11]，每个决策步骤允许最多三个内部循环的思考-动作-观察。智能体首先生成一个显式的推理轨迹，然后选择并执行一个工具，观察结果后再决定是继续推理还是提交运动动作。内部循环在调用运动工具或终止工具时终止。该模式通过注入一个模式技能激活，该技能指示VLM将推理与工具使用交替进行，适用于在提交动作前需要收集信息的任务。

前瞻模式 受深思熟虑的搜索策略（如思维树 [22]，）启发，该智能体针对高不确定性场景采用两阶段深思熟虑过程。在规划阶段，VLM生成三个候选动作，每个动作均附带预测结果和风险评估。在选择阶段，第二次VLM调用评估候选动作并选择具有最有利预测结果的那一个。该模式通过注入两种互补的模式技能（一种用于规划，一种用于选择）激活，提供最高认知深度，使智能体能够在采取行动前推理行动后果。如果规划阶段产生格式错误输出，系统会优雅地降级为直接选择调用。

所有三种模式都仅通过模式技能注入来激活，并且与任务特定技能完全解耦。切换模式只需要进行配置更改，无需修改代理的决策循环或任务知识。

分层内存为了支持跨步推理，SpaceMind维护了一个双层记忆系统。近期记忆保留了最近 N 步的详细记录，包括代理的分析、工具选择、论点和结果。长期记忆将较旧的步骤压缩为自然语言摘要，该摘要捕获了累积的轨迹信息。这两个层级被连接并作为上下文输入注入到每个VLM调用中，使代理能够检测并从目标丢失中恢复，避免重复失败的策略，并在扩展的场景中跟踪任务完成的进度。

3.4 接口与通信架构

SpaceMind 的一个关键设计目标是相同的代理代码库可以在不同的物理环境中运行而不需要修改。实现这一点需要将代理的决策逻辑与任何特定传感器或执行器后端的细节解耦。SpaceMind 通过两个抽象层实现这种解耦：一个代理-工具协议和一个工具-环境通信总线。

MCP 工具协议 所有可执行的功能都通过模型上下文协议（MCP） [10]，暴露给代理，这是一个用于连接语言模型到外部函数的标准接口。代理通过统一的调用约定通过名称和参数调用工具，而无需了解每个工具是如何实现的。工具被组织成四个功能类别：

- **感知工具** 分析当前的视觉输入，包括亮度评估、部件级分割、区域裁剪和缩放。
- **控制工具** 发出运动和传感器命令，如平移和旋转运动、相机曝光调整和任务终止。
- **知识工具** 提供对描述航天器特征的领域知识库的访问。
- **辅助工具** 支持可选功能，例如数值计算中的代码执行。

一个 **工具配置** 机制控制智能体在给定实验中可见的工具。每个配置指定一个允许工具白名单；在运行时，只有同时出现在MCP服务器的完整目录和活动配置的白名单中的工具才会呈现给VLM。这通过配置本身实现了受控的消融研究（例如，移除测距以测试仅视觉操作）和环境特定工具集（例如，物理实验室的最小配置）。

有两个设计决策值得讨论。首先，平移和旋转运动作为单独的工具暴露，而不是一个6自由度命令，防止VLM产生耦合的平移-旋转动作，这在早期开发中观察到是一种失败模式。其次，相机曝光调整作为显式工具暴露，使智能体能够在检测到曝光不足或曝光过度时主动提高其感知质量，而不是被动接受退化图像。

Redis 消息总线 在 MCP 工具实现与物理环境之间，一个 Redis 发布-订阅消息总线提供了第二层抽象。一个统一的命名契约定义了通信通道：传感器数据通过指定的键（例如，最新的 RGB 图像、最新的 LiDAR 汇总）和图像到达通知向上流动，而控制命令通过相应的命令主题向下流动（例如，姿态变化增量、

曝光调整)。在 UE5 模拟中, 一个 AirSim [32] 桥接进程将传感器数据写入 Redis 并消耗运动命令。在物理实验室中, 一个 ROS2 传感器桥接器将相机帧发布到相同的 Redis 键, 并且一个单独的运动执行器订阅相同的命令主题以驱动移动机器人。两个后端填充并消费相同的 Redis 通道; 代理的决策循环不包含环境条件逻辑。

这种双层抽象提供了一个具体的可移植性保证: 相同的智能体决策循环、MCP 工具服务器和通信合约在两种环境中均无需代码修改即可运行。将 SpaceMind 扩展到新的环境后端只需要为该后端的传感器和执行器实现 Redis 读写端点。

3.5 技能自进化机制

在轨空间服务本质上是一个重复执行领域: 相同的任务类型在不同目标和条件下会重复出现。一个在每次场景结束后抛弃所有操作经验的智能体会错失从自身成功和失败中改进的机会。传统适应方法不适用于此场景: 模型微调需要标记训练数据和梯度计算, 强化学习要求显式奖励函数设计, 情境学习受上下文窗口限制且不会跨会话持久化, 而检索增强生成只能检索现有文档而非合成新知识。SpaceMind 引入了一个技能自进化机制, 使智能体能够在场景间自主生成、验证和积累操作知识, 而无需修改模型权重。

该机制作为标准决策循环的外部循环运行 (图2, 右侧)。每个场景结束后, 执行以下流程:

场景总结 系统记录完整的工具调用轨迹、后继失败结果、终止原因, 以及智能体在场景中的运动和感知历史的结构化总结。

经验反思 场景总结, 连同最近先前场景的总结和当前活动的技能定义, 通过专门的反思调用提供给 VLM。VLM 分析哪些有效、哪些失败以及原因, 并生成结构化的变异决策, 指定五种动作之一: 创建一个新的学习技能, 捕获以前未知的操作模式; 叠加现有技能, 添加改进或补充规则; 重写现有技能, 当证据表明需要进行根本性修订时; 禁用已被发现有害的学习技能; 或不_更改, 当当前经验不足以证明修改时。

质量门 每个拟议的变异在应用之前都通过多阶段验证门。该门强制执行四个约束:

- 安全短语黑名单会拒绝包含可能覆盖安全规则的指令的突变。
- 指纹去重检查可防止语义冗余的技能累积。
- 任务范围绑定确保在一个任务上下文中学习的技能不会污染其他任务的知识库。
- 父技能验证确认覆盖和重写操作的目标是实际存在的技能。

突变

在失败时任何约束都会被丢弃，并且审计日志记录了拒绝原因

n.

学习技能生成 通过质量门的突变会被具体化为新的技能文件，这些文件与手写技能具有相同的格式，以确保与现有的技能路由基础设施兼容。每个学习技能包含五个结构化部分：意图 指定技能旨在实现的目标，触发器 定义技能应激活的条件，规则 编码操作指令，约束 界定安全边界，以及证据 记录激励技能的场景观察。额外的元数据记录技能的来源、版本、原始场景和适用任务范围。

自动注入 在每个后续场景开始时，技能运行时加载所有学习技能以及基础技能集。检索函数根据其声明的范围和触发条件，将学习技能与当前任务和推理模式进行匹配，选择最相关的 k 个学习技能，连同动态路由的基础技能一起注入系统提示。

此设计具有四个特性，使其区别于先前的自我改进方法。首先，学习技能与模块化技能架构（第 3.2 节）天然兼容：它们使用相同的数据格式，通过相同的路由管道，并与基础技能组合而不需要特殊处理。其次，知识是持久且可审计：每次突变都记录了完整的来源，并且技能文件可以被操作员检查、编辑或还原。第三，进化是渐进的：技能通过版本覆盖逐步积累，而不是整体替换，允许逐步优化。第四，质量门提供安全保证：即使 VLM 的反射产生不安全或冗余的建议，硬约束也会阻止其进入活动技能集。

4 实验验证

我们通过组织为四个实验活动、在具有高保真度的虚幻引擎5（UE5）模拟和物理实验室环境中进行的192次闭环运行来评估SpaceMind。表1总结了这些活动。工具消融实验验证了模块化工具配置机制。推理评估活动在五个卫星、三个任务和三个初始条件下系统地比较了推理模式。自我进化活动通过迭代执行测试自主技能的改进。实际应用案例通过零代码修改验证了跨环境可移植性。

表1: 实验活动概述。

活动	Env	Runs
工具消融	UE5	9
推理评估	UE5	135
自我进化	UE5	30
现实世界	AGV Pro	18
总计		192

4.1 实验设置

模拟环境 该模拟基于UE5构建，并使用AirSim插件 [32], 扩展SpaceSense-Bench平台 [33] 以提供高保真光学渲染和多传感器模拟。场景中放置了五个几何形状和尺寸各异的卫星模型：CAPSTONE、IBEX、BioSentinel、新视野和惠更斯。智能体通过RGB相机和LiDAR测距传感器感知环境，并通过MCP [10]工具调用，通过Redis消息总线控制其6-自由度位置和姿态。

实验室环境 物理测试平台由一个配备麦克纳姆轮和40公斤有效载荷的myAGV Pro全向移动机器人组成，在 1920×1080 分辨率处配备了Orbbec Gemini 2立体RGB相机。该机器人运行ROS2 Humble，并通过Redis桥接器与相同的智能体决策循环通信。两个1米直径的3D打印卫星模型CAPSTONE和阿耳忒弥斯作为目标。运动被约束在一个3自由度平面工作空间内。

任务 表2中定义了三种难度递增的任务类型。

表2: 任务定义和评估指标。

Task	缩写	描述	指标
会合	轮次	目标可见；接近到 $\sim 2\text{m}$	成功，距离，步数
搜索与接近	搜索	目标不可见；找到后接近 $\sim 2\text{m}$	成功，距离，步数
检查	灵感	近距离 5维结构化报告	分数 (0-100)

初始条件 UE5模拟中使用了三种初始条件来评估鲁棒性（表3）。所有三个任务都在每种条件下进行了测试。

表3: UE5模拟的初始条件定义。

条件	位置	曝光	困难
C1	标称	标称	基线
C2	远侧偏移	曝光不足	退化
C3	反向偏移	曝光过度	退化

VLM骨干 所有实验均使用开源的Qwen3-VL-235B-A22B模型 [34]作为VLM决策核心，并使用温度 ≤ 0.3 来促进所有活动中的输出稳定性。

4.2 工具配置消融

为验证模块化工具配置机制，工具消融实验在固定条件下比较了三个工具配置文件，具体为CAPSTONE与C1的标准模式。每个配置文件向智能体暴露不同子集的MCP工具：仅视觉仅提供相机感知，混合导航增加激光雷达距离感知，而混合导航代码进一步增加运行时代码执行。表4展示了结果。

没有LiDAR距离测量，仅视觉配置由于距离估计误差导致超调，因此两个导航任务都失败。混合导航在所有任务上以最少的步数和最高的检查分数成功，而添加运行时代码执行并不能提高性能，因为智能体在实际中从未调用代码执行工具。基于这些结果，混合导航被采用为后续所有实验的默认配置，这表明SpaceMind的工具配置文件机制允许声明式能力配置。

表4: 工具配置消融结果 (共9轮)。

工具配置	轮次		搜索		导航通过	灵感
	距离(m)	步数	距离(m)	步数	Rate	分数
仅视觉	FAIL		FAIL		0/2	65
混合导航	2.006	9	2.277	16	2/2	65
混合导航代码	2.048	13	2.279	15	2/2	50

基于这些结果，混合导航被采用为后续所有实验的默认配置，这表明SpaceMind的工具配置文件机制允许声明式能力配置。

4.3 多卫星推理模式评估

推理评估活动提供了跨5颗卫星、3项任务、3种推理模式（标准、ReAct [11],前瞻性）和3种初始条件的系统比较，总计135次运行。

4.3.1 结果

表5汇总了所有模式和条件下的导航和检查结果。图3可视化了从C1到C3的导航通过率退化。

表 5: 跨条件推理模式评估结果，总计 135 跑。导航报告每 5 跑的任务类型通过次数；检查报告每 5 跑的平均分。每列的最佳值**加粗**。

Mode	轮次 (通过 / 5)				搜索 (通过 / 5)				Nav. 总计		灵感 (平均分)			
	C1	C2	C3	Sub	C1	C2	C3	Sub	Pass	距离 (m)	C1	C2	C3	Avg
标准	5	5	3	13 (87%)	4	0	0	4 (27%)	17/30 (57%)	2.143	40.2	41.0	36.2	39.1
ReAct	5	1	2	8 (53%)	5	0	0	5 (33%)	13/30 (43%)	2.177	38.6	40.8	42.8	40.7
前瞻性	5	3	2	10 (67%)	4	1	2	7 (47%)	17/30 (57%)	2.079	36.6	22.6	29.8	29.7

4.3.2 分析

结果表明 没有单一的推理模式占主导，而 Rndz./搜索 的分割暴露了根本不同的退化模式。在 C1 条件下，目标可见且条件标称时，所有三种模式均达到 5/5 会合成功。标准模式即使在 C2 条件下也保持完美会合，达到 5/5，并在 87% 的会合子项总计 13/15 中取得最高会合总分。然而，在退化情况下，其搜索性能完全崩溃：在 C2 和 C3 中均为 0/5，仅产生 4/15 或 27%。ReAct 显示出类似模式，在 C1 下实现完美 5/5 会合和搜索，但在 C2 下会合和搜索降至 1/5 和 0/5，大多数失败达到 50 步超时，因为当目标远离预期位置时，思考-行动-观察循环发生振荡。

前瞻性是唯一在退化条件下实现任何搜索成功的模式：在C2处为1/5，在C3处为2/5，在47%处产生7/15的搜索总计，几乎是标准27%的两倍。其候选预测机制通过在承诺之前评估多个运动假设来避免盲目探索，产生了最精确的终端距离2.079米。这一优势




图3：不同初始条件下的导航通过率。ReAct从C1到C2退化明显，而标准和前瞻性保持更高的鲁棒性。

仅针对搜索和接近任务，其中目标必须首先被找到；对于会合任务，其中目标已经可见，标准就足够了，而额外的推理开销并无益处。

进行检查时，出现了一个反直觉的模式：ReAct在C3下达到最高分42.8，超过标准36.2和前瞻性29.8。ReAct的快速终止策略（1-3步）限制了幻觉累积，而前瞻性的两阶段推理在退化视觉条件下放大了VLM幻觉风险。这些发现验证了SpaceMind的模块化推理架构可以承载根本不同的策略，系统性比较为部署提供了可操作的模式选择指导。

4.3.3 技能路由验证

为验证动态技能路由机制，我们从所有135次运行中提取路由决策。技能网关正确地将每个任务路由到其预期的技能集：会合到接近 + 距离技能；搜索与接近到搜索 + 目标恢复 + 距离技能；和检查到检查 + 感知技能。路由在所有运行中均与预期分配达成100%一致，无需人工干预，证实基于LLM的技能网关能够可靠地从模块化目录组合任务合适的技能集。

4.4 技能自进化

自进化活动评估技能自进化机制是否可以通过重复执行积累有用的操作知识。我们选择跨越三颗卫星和两种任务类型的六个组，优先选择推理评估基线失败或得分低的组合。每个组进行五轮连续运行，使用共享进化工作空间，采用标准模式和混合导航工具配置文件。每轮结束后，进化运行时回顾场景，并可能生成学习技能文件，这些文件会自动注入后续轮次。表6总结了结果，图4显示了每轮学习曲线。

最引人注目的结果是该机制从失败中恢复的能力。两个组

表6：跨6组30次运行技能自进化结果。BL = 基线来自推理评估活动。

卫星	Task	Cond	基线		进化后最佳		裁决
			结果	详情	结果	详情	
CAPSTONE	搜索	C1	OK	2.597米	0/5	—	无益
CAPSTONE	灵感	C2	50分	—	65 pt	+30%	阳性
新视野	搜索	C1	FAIL	10 st	3/5	2.102 m	阳性
新视野	轮次	C3	FAIL	20 st	5/5	7 st	Strong +
惠更斯	轮次	C2	OK	2.209 m	3/5	2.169 m	无益
惠更斯	灵感	C1	12 pt	—	68 pt	+467%	Strong +




图4：六个组的技能自进化学习曲线，按任务类型在列中组织，分别为Rndz.、搜索和灵感。对于导航组，条形图显示成功，虚线显示步数；对于检查组，实线显示分数，虚水平线标记基线水平。绿色表示明显的正向收益；灰色表示没有显著改进。

在基线完全失败，即新视野搜索C1和新视野区域C3，在自我进化后分别达到60%和100%的成功率。在新视野区域C3中，步数在五轮中从20稳定收敛到7，表明自动生成的学习技能编码了一种有效的距离相关步长减少策略。六个组中的三个在第一轮或第二轮时显示出显著改进，证明反射机制可以从单个失败事件中提取可操作的知识。

对于检查任务，两组都通过叠加变异机制表现出一致收益：CAPSTONE Insp. C2 从 50 提升至 65 分，Huygens Insp. C1 从 12 提升至平均 59.4 分。感知策略的增量叠加优化对此任务类型特别有效。

对此任务类型特别有效。

然而，在基线已经成功的两个组别中，CAPSTONE 搜索 C1 和惠更斯圆形区域 C2，并不能从自我进化中获益，这表明该机制的主要价值在于错误纠正和策略发现，而非优化已经成功的行為。在所有组别中，标准技能文件格式中生成了七个学习技能，并在后续轮次中由技能网关正确路由，这证实了自我进化机制与模块化架构之间的兼容性。

4.5 现实世界验证

实际应用案例验证了相同的架构，包括相同的智能体循环、MCP 工具签名和 Redis 通信合约，可以在无需代码修改的情况下操作物理机器人；仅需将物理后端更换为 ROS2 传感器桥和电机控制器。表 7 展示了在两个卫星模拟器、三个任务和每个组合三次重复的情况下，总计 18 次运行的结果。

表 7: 18 次运行的实际世界验证结果。

卫星	Rndz.			搜索			灵感	
	Pass	Runs	Rate	Pass	Runs	Rate	平均分	Runs
CAPSTONE	3	3	100%	2	3	67%	41.0	3
阿耳忒弥斯	3	3	100%	2	3	67%	34.0	3
总计	6	6	100%	4	6	67%	36.8	6

智能体在会合任务上实现了完美的 6/6 通过率，在搜索和接近任务上实现了 4/6 的通过率。有三个观察结果是针对物理环境的。首先，智能体在模拟中每步的步长从 1-2 米自动调整为实验室中的 0.1-0.2 米，展示了涌现的尺度感知，而无需显式重新配置。其次，目标恢复技能的偏航 $\pm 90^\circ$ 扫描模式从模拟中完全转移，确认了行为一致性。第三，一次检查运行由于 15 次迭代中的累积小步导致碰撞，突出了近距离操作中需要显式安全裕度的必要性。图 5 从第三人称视角说明了代表性的搜索和接近场景。这些结果验证了接口和通信架构，并证明了 SpaceMind 的模块化设计能够泛化到不同环境。

4.6 定性分析

我们选择了四个具有代表性的场景，这些场景说明了 SpaceMind 的设计所支持的涌现行为。图 6 展示了每个场景的关键帧图像。

示例 1: 实验室目标丢失恢复 在实验室中执行 CAPSTONE 搜索任务期间，从初始姿态（图 6a）无法看到目标。在目标恢复技能的指导下，智能体执行了六个 15° 右转的有限偏航扫描，然后执行了九个 15° 左转，在检测到目标并切换到接近模式之前。该场景跨越了 42 步，在 1.13 米处终止，展示了模块化技能知识与分层记忆系统之间的相互作用。




图 5: CAPSTONE 在 14 步中完成真实世界搜索接近场景的第三人称视角。智能体在步骤 1-4 通过偏航扫描搜索目标，在步骤 5-8 对齐并接近，在步骤 12 恢复横向漂移，并在步骤 14 在目标表面 0.8 米处终止。

示例 2：主动曝光调整 在欠曝光 C2 条件下，初始相机图像几乎为黑色。智能体调用了亮度诊断工具，然后调用曝光控制工具来增加相机曝光。调整后，目标变得清晰可见（图 6c-d），智能体继续进行检查。这突出了 SpaceMind 作为决策控制中心的作用，它主动调整传感器参数，而不是被动地消耗退化图像。

示例 3：前瞻性候选预测 在 C2 下的新视野搜索任务中，标准和 ReAct 都在 50 步超时的情况下失败，但前瞻性在 29 步、2.007 米处成功（图 6e-f）。规划器生成三个具有预测结果和风险分数的候选运动方向；选择器选择风险最低的选项，避免了导致其他模式超时的盲目探索。

示例 4：自我进化故障恢复 在新地平线实验组 C3 组中，基线在 20 步时失败。经过一轮自我进化后，进化运行时生成一个学习技能，编码了距离相关步长减少策略。智能体从第 1 轮开始持续成功，五轮内步数从 20 收敛到 7（图 6h）。学习技能被持久化为标准技能文件，使其可审计、可移植，并由技能网关自动路由。




图 6: 智能体传感器视图的定性示例。顶行: (a–b) 实验室搜索, 其中目标在步骤 1 不可见, 但在步骤 42 被找到并接近; (c–d) C2 下的检查, 其中图像在步骤 1 几乎为黑色, 在步骤 10 激活曝光调整后清晰。底行: (e–f) C2 下的前瞻性搜索, 步骤 1 视图为空, 目标在步骤 29 到达; (g–h) 新视野区域 C3 的自我进化, 显示步骤 1 的基线, 在步骤 8 学习技能注入后成功接近。

5 讨论

框架定位和模块化SpaceMind 被设计为用于太空操作的模块化、自我进化的具身智能体基础设施。其价值在于渐进式分层: 模块化知识、工具和推理; 具有分层内存的多模式推理; 技能自我进化; 以及闭环跨环境验证。实验结果证实了这一设计: 技能路由网关在所有 135 次运行中实现了 100% 正确的任务到技能组合; 工具消融研究验证了即插即用能力配置; 现实世界活动展示了零代码修改跨环境迁移。值得注意的是, 智能体表现出涌现的尺度感知, 在模拟中从 1–2 米自主减少步长到实验室中的 0.1–0.2 米, 表明 VLM 可以从视觉上下文中推断环境尺度。

推理模式选择指南 没有单一的推理模式占主导地位, 但每种模式都有其明确的操作模式, 只有在分别报告会合和搜索与接近时才能看到。对于会合, 如果目标是可见的, 标准模式达到 13/15 或 87%, 在 C1 和 C2 处 100% 成功; 额外的推理开销无益。对于搜索与接近, 如果目标不可见, 标准模式和 ReAct 在 C2 和 C3 下都崩溃到 0/5, 而前瞻模式是唯一成功的模式, 搜索子项为 7/15, 成功率为 47%。对于检查, ReAct 在 C3 下获得最高分数 42.8, 因为其快速终止限制了幻觉累积, 而前瞻的两阶段链则累积了错误。在实践中, 人们可能会默认

到标准模式，并在检测到搜索阶段超时时切换到前瞻模式

自我进化机制见解 该机制在错误纠正 方面表现出色，但对于已成功的行为提供有限的价值。所有四个改进组在基线时失败或得分较低，而两个成功的基线则无益。因此，该机制最宝贵的价值在于作为自动故障恢复系统。学习速度很快：三个组在第一轮或第二轮时通过单个失败事件显著改进。与Voyager [31], Reflexion [29], 和ExpeL [30]相比，SpaceMind增加了结构化技能格式兼容性、带指纹去重的质量门，以及在安全关键物理3D环境中的运行。

局限性和未来方向 当前的VLMs具有有限的3D空间理解能力；SpaceMind通过技能知识和自我进化进行补偿，但智能体在退化条件下仍然偶尔会误判空间关系。当基线已经成功时，自我进化机制没有提供任何价值，而任务范围绑定约束阻止了跨任务技能迁移，这限制了其范围仅限于故障恢复。18次运行的实验室验证证明了架构可行性，但缺乏对细粒度声明的统计效力，并且UE5模拟没有包含轨道动力学约束。未来的工作包括在太空环境中训练VLMs进行3D空间推理，集成轨道动力学，以及在轨部署安全智能体决策（例如，相机曝光和传感器指向控制），其中决策控制中心角色可以在不危及航天器安全的情况下进行验证。

6 结论

本文介绍了 SpaceMind，一个用于自主在轨服务的模块化和自进化的具身视觉语言智能体框架。该框架做出了四项渐进式的贡献。首先，模块化架构通过带动态路由的技能模块、具有可配置配置文件的基于 MCP 的工具和可注入的模式技能，将智能体知识、工具和推理分解为独立可扩展的维度，使得同一代码库无需修改即可在模拟和物理环境中运行。其次，三种可切换的推理模式和分层记忆提供了可配置的认知深度，跨 135 次运行的系统评估表明没有单一模式占主导地位，每种模式在不同的操作模式下都表现出色。第三，技能自进化机制通过经验驱动的知识生成实现自主部署后的改进；在六组 30 次运行中，四组实现了显著的正向增益，包括从完全失败到 100% 恢复以及检查分数从 12 提高到 59，而两组揭示了该机制的边界条件。第四，跨 UE5 模拟和物理实验室的 192 次闭环验证为每个设计决策提供了经验证据，并生成了空间智能体系统中推理模式选择和工具配置的可操作的工程指南。

SpaceMind 证明，一个结构良好的模块化智能体框架，结合自主知识进化，可以作为强大的决策控制中心，用于复杂、长时程空间操作，从而弥合当前 VLM 能力与自主在轨服务需求之间的差距。

致谢

这项工作得到了中国国家重点研发计划（项目编号2024YFB3909300）的支持。

参考文献

[1] 菲利普·安兹-米多。轨道碎片季度新闻。轨道碎片季度新闻 (ODQN) , 24(JSC-E-DAA-TN77633), 2020.[2] 戴尔·阿尼, 理查德·萨瑟兰, 约翰·穆尔万尼, 德文·斯蒂恩科尼格, 克里斯托弗·斯托克代尔, 和梅森·法利。在轨服务、组装和制造 (osam) 现状, 2021。NASA OSAM 状态报告.[3] A.弗洛雷斯-阿巴德, O.马, K.范, 和S.乌尔里希。在轨服务空间机器人技术的综述。航空航天科学进展, 68:1–26, 2014.[4] 詹妮弗·哈巴格和B.邓巴。在轨服务、组装和制造2 (osam-2) 。STMD: 技术演示任务, 2022.[5] 罗宾·比斯布鲁克, 萨尔马德·阿齐兹, 安德鲁·沃尔汉, 斯特凡诺·奇波拉, 米蕾尔·理查德-诺卡, 和卢克·皮格。clearspace-1任务: 欧洲航天局和clearspace合作清除碎片。在第8届欧洲空间碎片会议论文集, 页面1–3, 2021.[6] 杰森·L·福绍, 古列尔莫·S·阿莱蒂, 尼马尔·纳瓦拉坦南, 哈瓦尔·卡德姆, 蒂埃里·萨蒙, 奥雷利安·皮塞尔, 埃里克·若夫, 托马斯·沙博, 因戈·莱塔, 罗伯特·阿克斯赫姆, 等。RemovedebriS: 在轨主动碎片清除演示任务。宇航员学报, 127:448–463, 2016.[7] 维克多·罗德里格斯-费尔南德斯, 亚历杭德罗·卡拉斯科, 杰森·程, 埃利·沙夫, 彭·文·肖, 和理查德·林纳雷斯。语言模型是航天器操作员。arXiv预印本 arXiv:2404.00413, 2024.[8] 亚历杭德罗·卡拉斯科, 马科·内东加迪, 维克多·罗德里格斯-费尔南德斯, 和理查德·林纳雷斯。视觉语言模型作为太空领域的操作智能体。在AIAA SCITECH 2025论坛, 页面1543, 2025.[9] 王磊, 马晨, 冯雪阳, 张泽宇, 杨浩, 张景森, 陈志远, 唐嘉凯, 陈旭, 林岩凯, 等。基于大型语言模型的自主智能体综述。计算机科学前沿, 18(6):186345, 2024.[10] 侯新怡, 赵岩杰, 王申傲, 和王浩宇。模型上下文协议 (MCP) : 格局、安全威胁和未来研究方向。ACM软件工程与方法学汇刊, 2025.[11] 姚顺宇, 赵杰弗里, 余狄安, 杜南, 伊扎克·沙夫兰, 卡尔提克·R·纳拉辛汉, 和曹远。ReAct: 在语言模型中协同推理和行动。在第11届学习表示国际会议, 2022.[12] 黄安东, 陈波, 和陈泰俊。用于检测、分割和部件识别的航天器数据集。在IEEE/CVF计算机视觉与模式识别会议论文集, 页面2012–2019, 2021.[13] 赵广元, 万雪, 田亚林, 邵亚东, 和李胜阳。非合作航天器用3D组件分割网络和数据集。航空航天, 9(5):248, 2022。

[14] 邵亚东, 吴奥迪, 李胜阳, 舒立政, 万雪, 邵元斌, 和 霍俊岩. 卫星组件语义分割: 视频数据集和实时金字塔注意力及解耦注意力网络. *IEEE 航空航天与电子系统汇刊*, 59(6):7315–7333, 2023.[15] 马特·基斯坦塔尔, 苏曼特·夏尔马, 朴泰哈, 达里奥·伊佐, 马库斯·马滕斯, 和 西蒙娜·达米科. 卫星姿态估计挑战: 数据集、竞赛设计及结果. *IEEE 航空航天与电子系统汇刊*, 56(5):4083–4098, 2020.[16] 朴泰哈, 马库斯·马滕斯, Gurvan Lecuyer, 达里奥·伊佐, 和 西蒙娜·达米科. Speed+: 领域差距下航天器姿态估计的下一代数据集. 在 *2022 IEEE 航空航天会议 (AERO)*, 页面 1–15. IEEE, 2022.[17] 朴泰哈 和 西蒙娜·达米科. 领域差距下航天器姿态估计的鲁棒多任务学习和在线优化. *空间研究进展*, 73(11):5726–5740, 2024.[18] 利奥·鲍利, 瓦西姆·拉尔巴维, 卡尔·申德勒, 阿伦库马·拉蒂南, 文森特·高迪里埃, 和 贾米拉·阿乌达. 基于深度学习的单目航天器姿态估计综述: 现状、局限性和展望. *宇航员学报*, 212:339–360, 2023.[19] 马修·福特, 普拉尼特·博杰, 罗汉·辛哈, 阿明·埃尔哈夫西, 索米拉塔·班纳吉, 克里斯托弗·阿吉亚, 贾斯汀·克鲁格, 托马索·古法蒂, 达尼埃莱·加梅利, 西蒙娜·达米科, 等. 为基于太空的任务适配基础模型. *arXiv 预印本 arXiv:2408.05924*, 2024.[20] 秦宇嘉, 胡圣顶, 林岩凯, 陈伟泽, 丁宁, 崔甘泉, 曾振怡, 周顺和, 黄宇飞, 肖超军, 等. 使用基础模型的工具学习. *ACM 计算机调查*, 57(4):1–40, 2024.[21] 魏健, 王学志, 戴尔·舒尔曼斯, 马滕·博斯马, 夏飞, 艾德·奇, 勒·秋克, 周登尼, 等. 思维链提示激发大型语言模型中的推理. *神经信息处理系统进展*, 35:24824–24837, 2022.[22] 姚顺宇, 余狄安, 赵杰弗里, 伊扎克·沙夫兰, 汤姆·格里菲斯, 曹远, 和 卡尔蒂克·纳拉辛汉. 思维树: 使用大型语言模型的刻意问题解决. *神经信息处理系统进展*, 36:11809–11822, 2023.[23] D. 德里斯, 夏飞, M. S. M. 萨贾吉, C. 林奇, A. 乔杜里, B. 伊彻, A. 瓦希德, J. 汤普森, Q. 武昂, T. 余, 等. PaLM-E: 一个具身多模态语言模型. *arXiv 预印本 arXiv:2303.03378*, 2023.[24] M. 安, A. 布罗汉, N. 布朗, Y. 谢博塔尔, O. 科尔特斯, B. 大卫, C. 芬恩, C. 傅, K. 戈伯, K. 高帕拉克里希南, 等. 做我所能, 而非我所言: 将语言与机器人可供性相结合. 在 *机器人学习会议 (CoRL)*, 2022.[25] W. 黄, 夏飞, T. 肖, H. 陈, J. 梁, P. 佛罗伦萨, A. 曾, J. 汤普森, I. 莫达奇, Y. 谢博塔尔, 等. 内心独白: 使用语言模型进行规划的身体推理. 在 *机器人学习会议 (CoRL)*, 2023.[26] 安东尼·布罗汉, 诺亚·布朗, 贾斯蒂斯·卡巴哈尔, 叶夫根·谢博塔尔, 陈希, Krzysztof Choro-manski, 丁天立, 丹尼·德里斯, 阿维纳瓦·杜贝, 切尔西·芬恩, 等. RT-2: 视觉-语言-动作模型将网络知识转移到机器人控制, 2023. URL <https://arxiv.org/abs/2307.15818>, 1:2, 2024.

[27] 金穆仁, 卡尔·佩尔施, 西达尔特·卡拉姆切蒂, 谢特·肖, 阿什文·巴拉克里什纳, 苏拉杰·奈尔, 拉斐尔·拉法伊洛夫, 伊森·福斯特, 格蕾丝·兰姆, 帕纳格·桑克蒂, 等. Openvla: 一个开源的视觉语言行动模型. *arXiv preprint arXiv:2406.09246*, 2024.[28] 毛嘉庚, 钱宇曦, 叶俊杰, 赵航, 王越. Gpt-driver: 使用GPT学习驾驶. *arXiv preprint arXiv:2310.01415*, 2023.[29] 诺亚·辛, 费德里科·卡萨诺, 阿什文·戈皮纳特, 卡尔蒂克·纳拉辛汉, 姚顺宇. Reflexion: 具有语言强化学习的语言代理. *神经信息处理系统进展*, 36:8634–8652, 2023.[30] 赵A, 黄D, 徐Q, 林M, 刘Y, 黄G. ExpeL: LLM代理是体验式学习者. In *人工智能AAAI会议论文集*, 卷38, 2024.[31] 王冠之, 谢宇琪, 蒋云帆, 阿杰·曼德卡, 肖超伟, 朱宇克, 范林熙, 安娜玛·安南库马尔. Voyager: 具有大型语言模型的开放式具身代理. *arXiv preprint arXiv:2305.16291*, 2023.[32] 希塔尔·沙, 德巴迪帕塔·迪, 克里斯·洛维特, 阿希什·卡普尔. Airsim: 自动驾驶车辆的高保真视觉和物理模拟. In *田野和服务机器人: 第11届国际会议成果*, 页码 621–635. Springer, 2017.[33] 吴奥迪, 左建红, 赵泽远, 罗旭波, 王瑞索, 万雪. Spacesense- bench: 用于航天器感知和姿态估计的大规模多模态基准. *arXiv preprint arXiv:2603.09320*, 2026.[34] 白帅, 蔡宇轩, 陈瑞哲, 陈克勤, 陈雄辉, 程泽森, 邓亮浩, 丁伟, 高畅, 葛春江, 等. Qwen3-vl技术报告. *arXiv preprint arXiv:2511.21631*, 2025.